NLP

Preprocesamiento de texto

Dr. Rodrigo Cardenas Szigety
rodrigo.cardenas.sz@gmail.com

Programa de la materia

Clase 1: Introducción a NLP, Vectorización de documentos.
Clase 2: Preprocesamiento de texto, librerías de NLP, bots de información.
Clase 3: Word Embeddings, CBOW y SkipGRAM, entrenamiento de embeddings.
Clase 4: Redes recurrentes (RNN), problemas de secuencia y estimación de próxima palabra.
Clase 5: Redes LSTM, análisis de sentimientos.
Clase 6: Modelos Seq2Seq, traductores y bots conversacionales.
Clase 7: Celdas con Attention. Transformers, BERT & ELMo, fine tuning.
Clase 8: Cierre del curso, NLP hoy y futuro, deploy.

*Unidades con desafíos a presentar al finalizar el curso.
*Último desafío y cierre del contenido práctico del curso.

Preprocesamiento de texto

LINK GLOSARIO

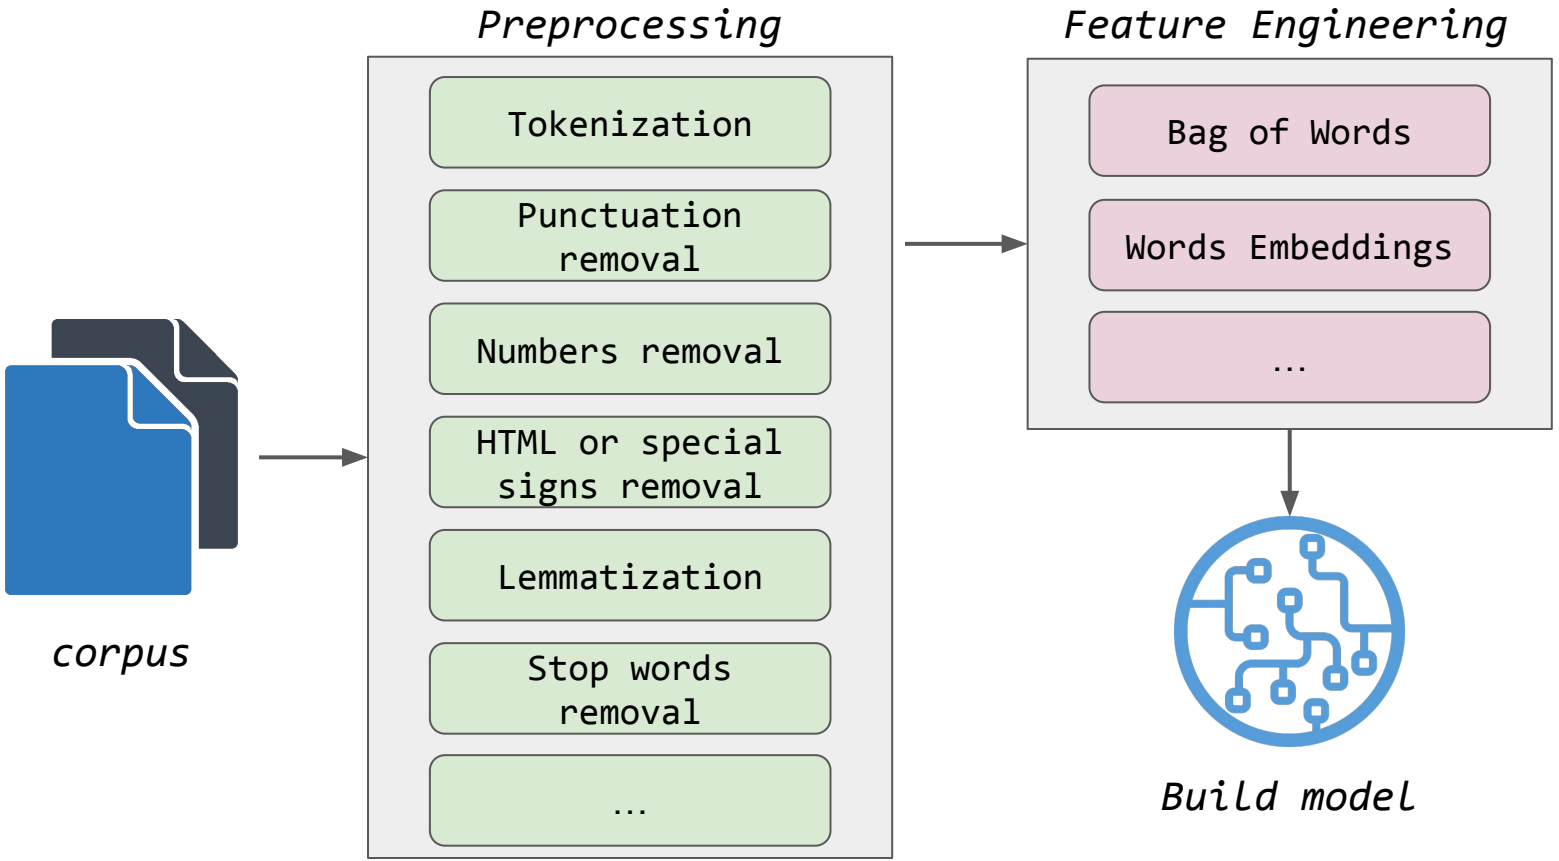

Tokenizar

Proceso en el cual una oración o documento es segmentado en términos individuales. Una vez finalizada la segmentación cada término único es referenciado mediante un token.

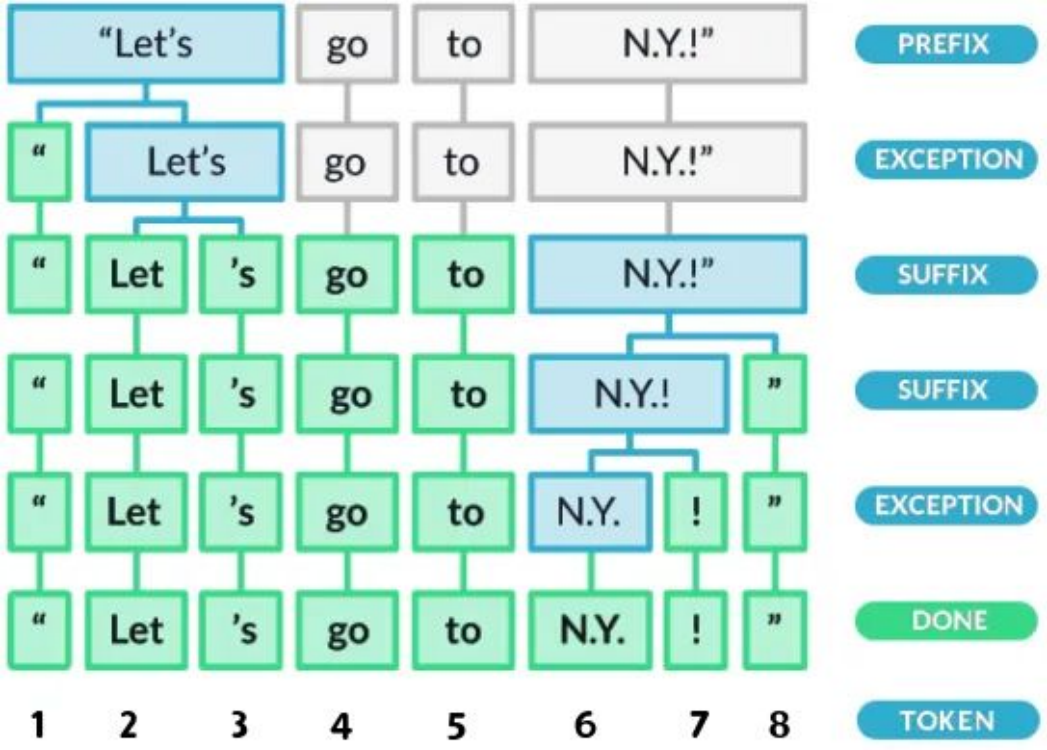

Derivado (steeming)

Aplica reglas de eliminación de patrones recurrentes de la lengua. El resultado es una palabra truncada que no será necesariamente la raíz morfológica de la palabra.

Regla: Eliminar los sufijos

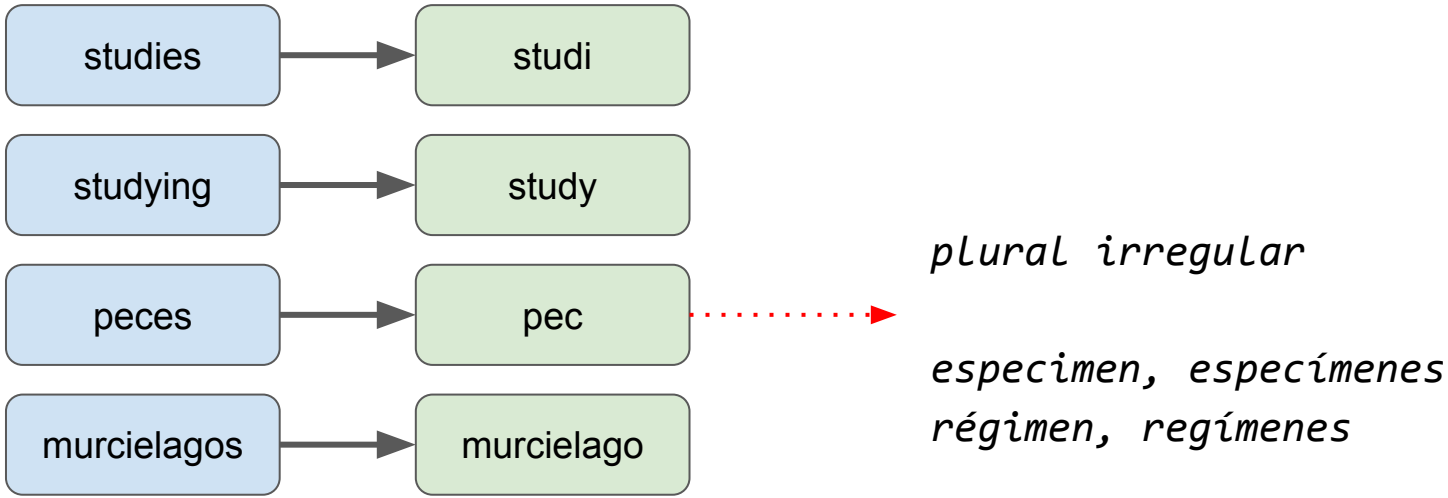

plural irregular

especimen, especímenes
régimen, regímenes

Lematización (lemmatization)

Devuelve la raíz morfológica de una palabra. Para ello se necesita un diccionario del idioma con todas las declinaciones posibles de las palabras raíz.

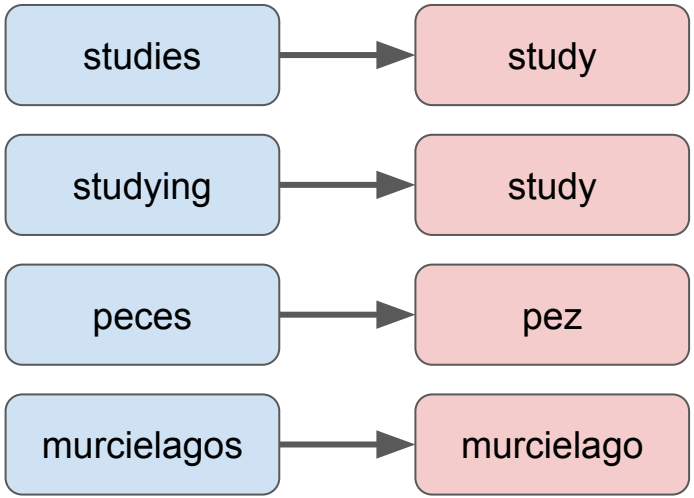

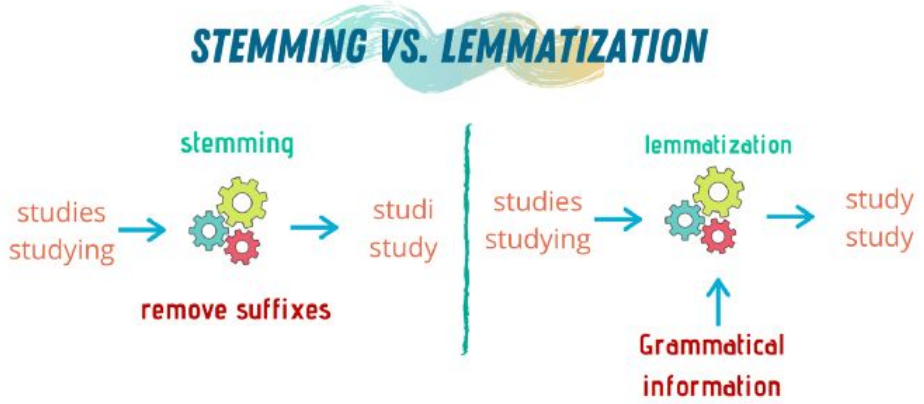

Parts-of-speech (POS) tagging

POS es el proceso de clasificar cada término en un texto en sus categorías gramaticales, etiquetándolos por ejemplo como ***sustantivo (noun), verbo (verb), adjetivo (adj),*** *etc*

Named-entity recognition (NER)

NER es el proceso de clasificar nombres propios de entidades en categorías predefinidas a las cuales pertenecen.

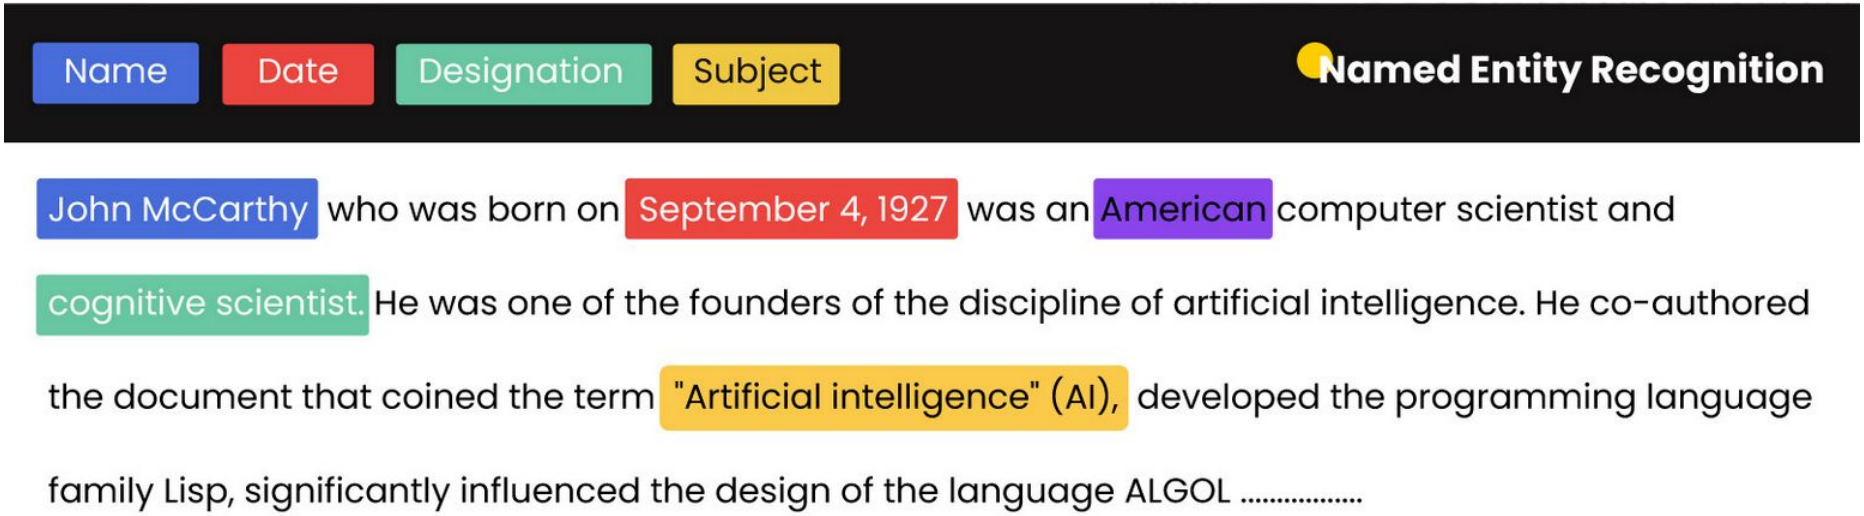

Stop words

Palabras que no aportan valor al significado de una oración ya que son muy frecuentes o comunes en el lenguaje

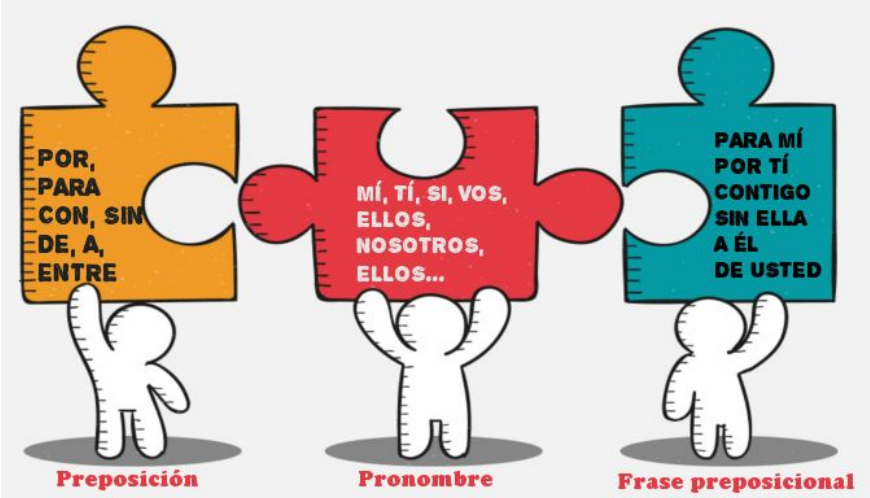

*Argentina, oficialmente, República Argentina, es **un** país soberano **de** América **del** Sur, ubicado **en el** extremo sur **y** sudeste **de** dicho subcontinente. Adopta **la** forma **de** gobierno republicana, democrática, representativa **y** federal.*

Argentina, oficialmente, República Argentina, es país soberano América Sur, ubicado extremo sur sudeste dicho subcontinente. Adopta forma gobierno republicana, democrática, representativa federal.

Stop words

Analizar un texto relacionado con calentamiento global (global climate)

Texto con Stop Words

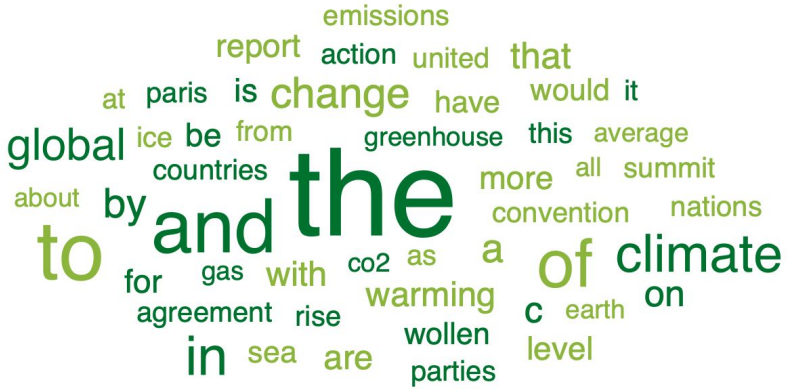

Texto sin Stop Words

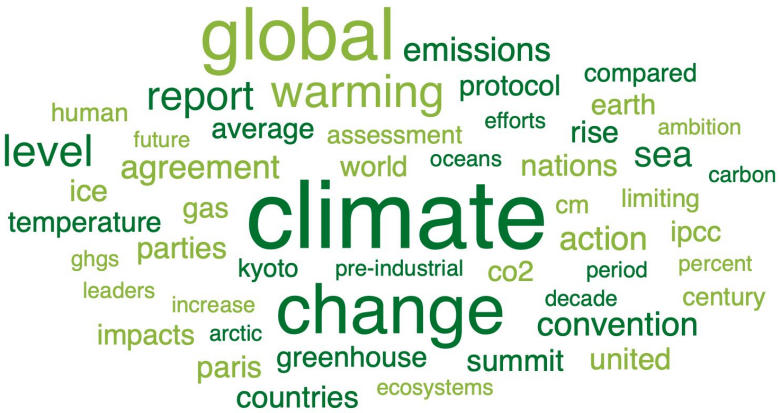

Las Stop Words pueden depender del contexto del corpus.

Librerías de NLP

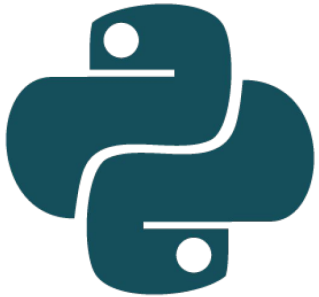

NLTK

- Gran comunidad de desarrollo
- No soporta GPU
- Más optimizada en CPU
- Más lenta en gran volúmenes de datos o operaciones

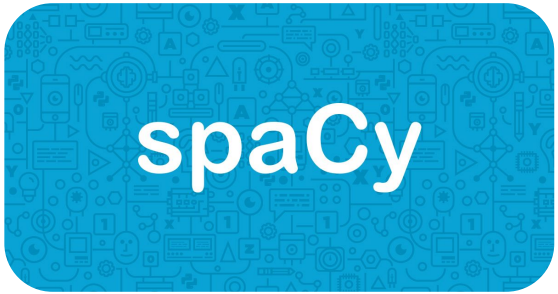

- Más moderna e implementa los últimos features
- Soporta GPU
- Menos optimizada en CPU
- Más rápida en gran volúmenes de datos o operaciones (GPU)

NLTK

LINK PÁGINA

"Librería por excelencia de procesamiento de lenguaje natural para Python"
Inicios 2009

Implementa una tool/algoritmo para cada etapa de preprocesamiento de NLP

spaCy

LINK PÁGINA

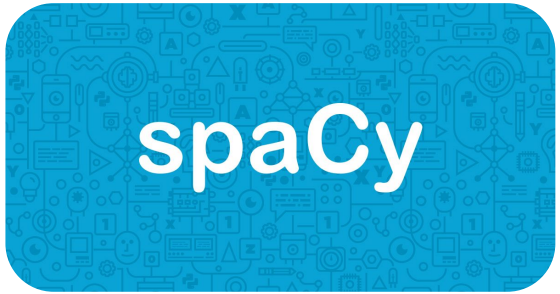

Inicios 2015

- Support for **72+ languages**
- **80 trained pipelines** for 24 languages
- Multi-task learning with pretrained **transformers** like BERT
- Pretrained **word vectors**
- State-of-the-art speed
- Production-ready **training system**

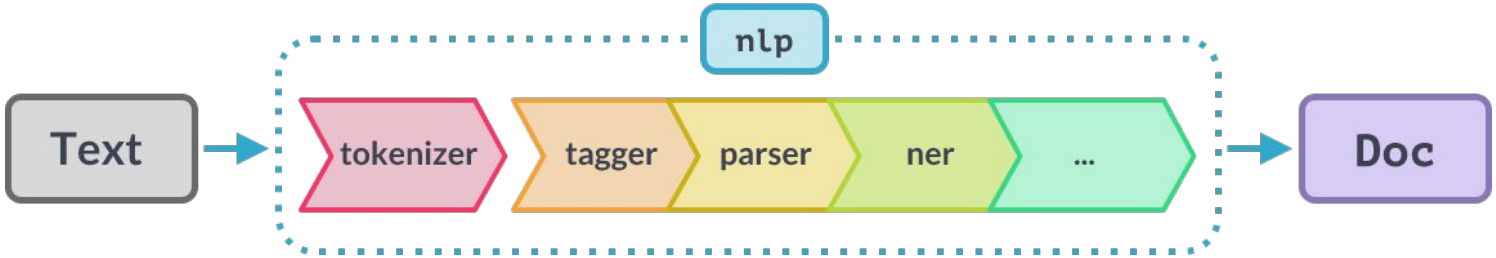

spaCy

LINK PÁGINA

```python
import spacy

nlp = spacy.load("en_core_web_sm")
doc = nlp("Apple is looking at buying U.K. startup for $1 billion")

for token in doc:
    print(token.text, token.lemma_, token.pos_, token.tag_, token.dep_,
            token.shape_, token.is_alpha, token.is_stop)
```

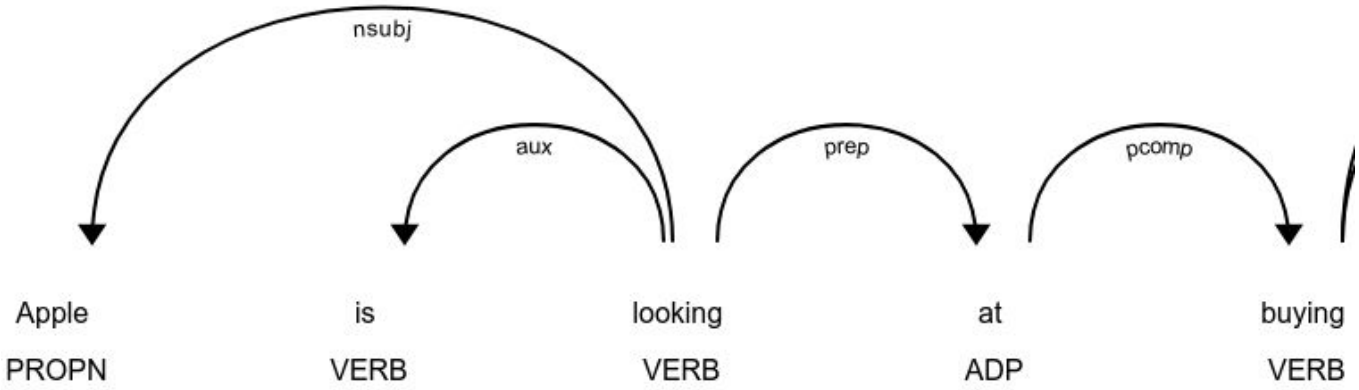

Un resumen de todo lo visto

POS TAG DEP

TEXT	LEMMA	POS	TAG	DEP	SHAPE	ALPHA	STOP
Apple	apple	PROPN	NNP	nsubj	Xxxxx	True	False
is	be	AUX	VBZ	aux	xx	True	True
looking	look	VERB	VBG	ROOT	xxxx	True	False
at	at	ADP	IN	prep	xx	True	True
buying	buy	VERB	VBG	pcomp	xxxx	True	False
U.K.	u.k.	PROPN	NNP	compound	X.X.	False	False
startup	startup	NOUN	NN	dobj	xxxx	True	False
for	for	ADP	IN	prep	xxx	True	True
$	$	SYM	$	quantmod	$	False	False
1	1	NUM	CD	compound	d	False	False
billion	billion	NUM	CD	pobj	xxxx	True	False

Preprocesamiento

Link al Colab

LINK

BOTs lingüísticos

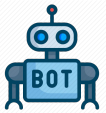

Son limitados a una tarea específica

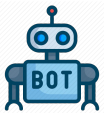

Fácil y "barato" de entrenar

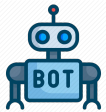

Ideal para chats de pedidos

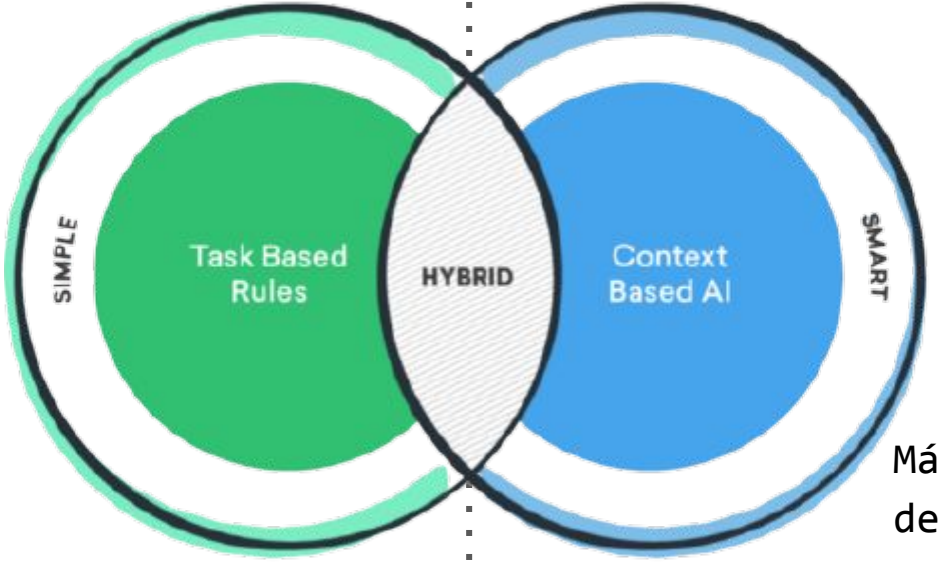

Interactúan casi como un humano

Más difíciles de entrenar, requieren más datos y cómputo

Ideal para asistentes virtuales

Sistema de obtención de información

Vectorizaremos texto de un corpus. Por ejemplo: párrafos u oraciones.

Vectorizaremos el texto de entrada y devolveremos la mejor coincidencia del corpus en términos de la similaridad coseno

$$\text{similarity} = \cos(\theta) = \frac{\mathbf{A} \cdot \mathbf{B}}{\|\mathbf{A}\|\|\mathbf{B}\|}$$

Probaremos el sistema armando una interfaz con gradio.

gradio

Sistema de obtención de información

Link al Colab

LINK

BOT de consulta abierta y respuesta predeterminada

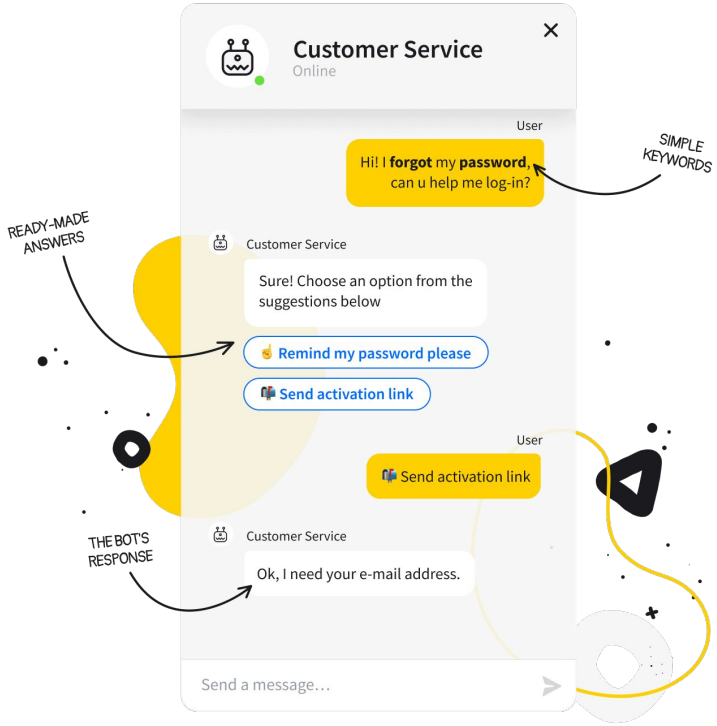

Nuestro bot será entrenado con <TAGS> (ej: saludo)

Cada <TAG> será representado por un patrón de posibles preguntas <patterns> (X)

Cada <TAG> tendrá uno o varias posibles respuestas <classes> (y)

BOT de consulta abierta

Link al Colab

LINK

Desafio

Tomar uno de los dos ejemplos mostrados y armar una versión propia