.UBAfiuba
FACULTAD DE INGENIERÍA

NLP

Long short term memory (LSTM)

Msc. Rodrigo Cardenas Szigety
rodrigo.cardenas.sz@gmail.com

Programa de la materia

Clase 1: Introducción a NLP, Vectorización de documentos.
Clase 2: Preprocesamiento de texto, librerías de NLP y Rule-Based Bots.
Clase 3: Word Embeddings, CBOW y SkipGRAM, representación de oraciones.
Clase 4: Redes recurrentes (RNN), problemas de secuencia y estimación de próxima palabra.
Clase 5: Redes LSTM, análisis de sentimientos.
Clase 6: Modelos Seq2Seq, traductores y bots conversacionales.
Clase 7: Celdas con Attention. Transformers, BERT & ELMo, fine tuning.
Clase 8: Cierre del curso, NLP hoy y futuro, deploy.

*Unidades con desafíos a presentar al finalizar el curso.
*Último desafío y cierre del contenido práctico del curso.

Limitaciones de las RNN

LINK

"Una celda RNN no puede mantener mucho el contexto o memoria (tienen problemas de short memory) pero se entrenan más rápido y son más baratas de ejecutar (tienen menos parámetros)"

Es muy probable que una celda RNN tenga un buen desempeño en la primera sentencia de ejemplo, pero muy improbable en la segunda por la distancia entre la palabra clave y la palabra objetivo:

Ejemplo 1:
"Vivo en Argentina desde muy pequeño, donde me enseñaron a hablar castellano"

Ejemplo 2:
"Vivo en Argentina desde muy pequeño, mis padres viajaron a Argentina en búsqueda de nuevas oportunidades. En la escuela me enseñaron a hablar muy bien castellano"

Grafo de cómputo de una RNN

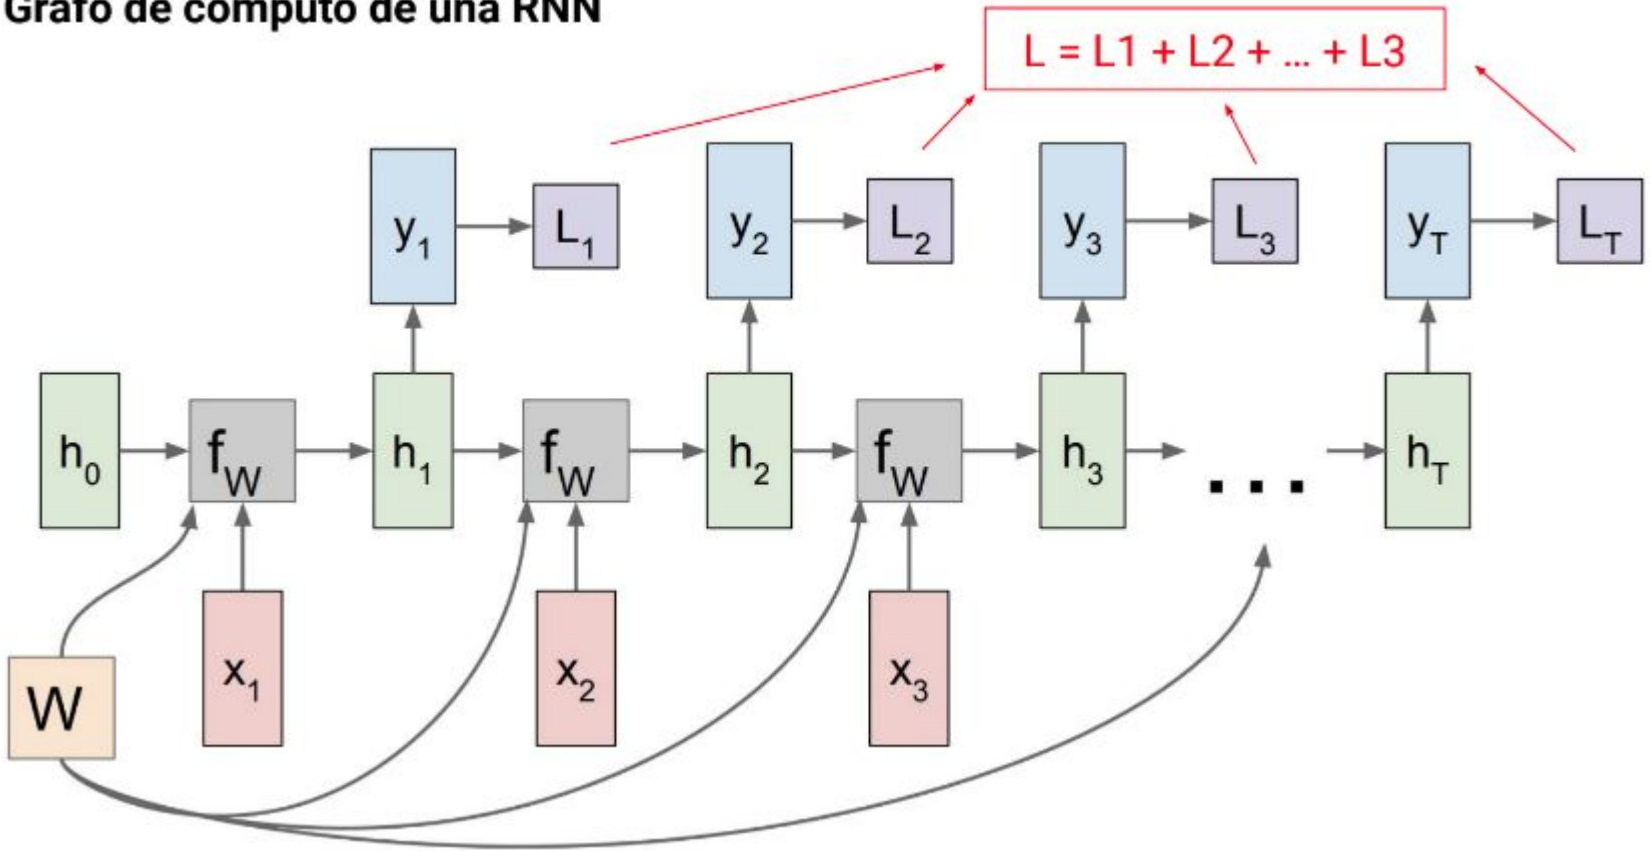

Long short term memory (LSTM) LINK

"Se introduce este tipo de celda neuronal con mayor persistencia de memoria para lograr capturar relaciones de palabras a largo plazo".

Se crearon en 1997, se adoptó como la layer principal para problemas de secuencia en 2014 y en 2018 unieron fuerzas con los "attentions".

Desplazaron completamente a las redes RNN, ya que el costo adicional de las LSTM es marginal respecto al beneficio que otorgan

Se basan en el principio de ponderar la importancia de una palabra respecto al contexto futuro/pasado (key words).

¿Comprarías este producto?

"Increible! El producto es lo que venden, hace lo que tiene que hacer y me ayudó mucho a resolver los problemas que tenía. Lo volvería a comprar sin dudas"

LSTM approach

LINK

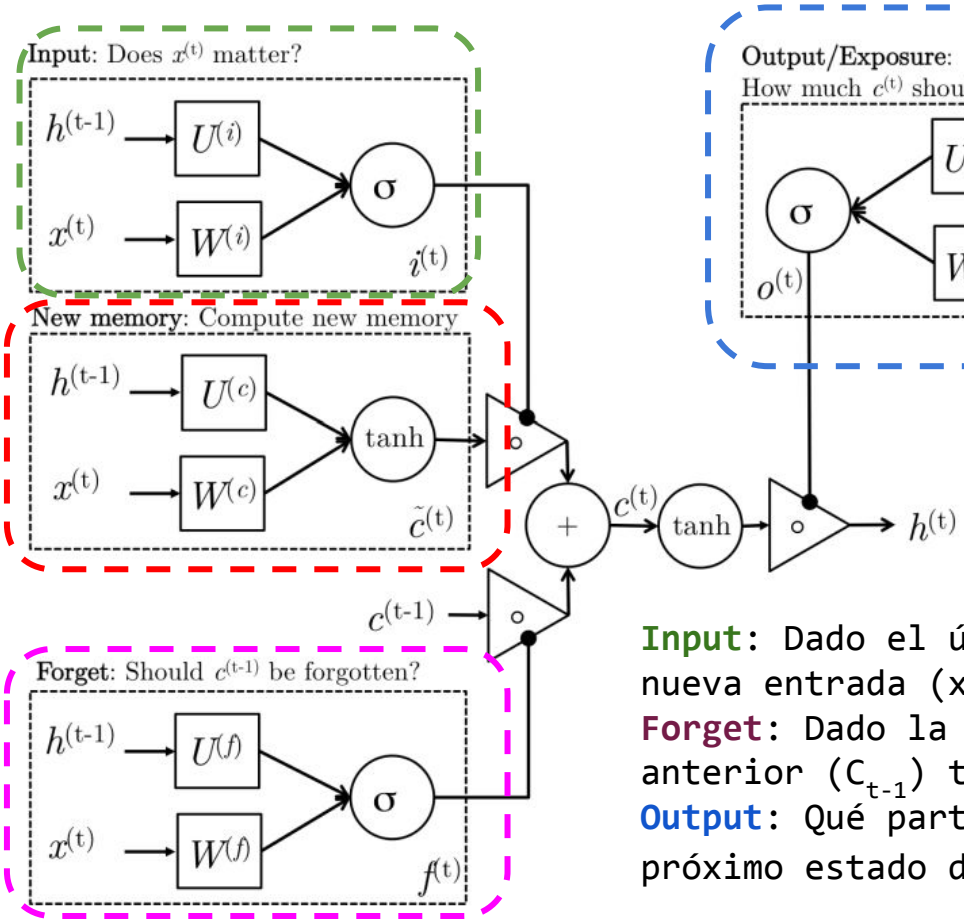

$$i_t = \sigma(W^{(i)}x_t + U^{(i)}h_{t-1})$$
$$f_t = \sigma(W^{(f)}x_t + U^{(f)}h_{t-1})$$
$$o_t = \sigma(W^{(o)}x_t + U^{(o)}h_{t-1})$$
$$\tilde{c}_t = \tanh(W^{(c)}x_t + U^{(c)}h_{t-1})$$
$$c_t = f_t \circ c_{t-1} + i_t \circ \tilde{c}_t$$
$$h_t = o_t \circ \tanh(c_t)$$

Input: Dado el último estado (h_{t-1}) evalúa cuánto de la nueva entrada (x) se incluirá en la memoria (C_t).
Forget: Dado la entrada (X) cuanto del estado de memoria anterior (C_{t-1}) tiene importancia en el nuevo estado.
Output: Qué parte del estado de memoria (C_t) pasa al próximo estado de memoria h_t.

(° es el producto elemento a elemento)

LSTM vs RNN

Las celdas RNN son mucho más simples pero no puede abordar problemas más complejos como los que veremos de seq2seq

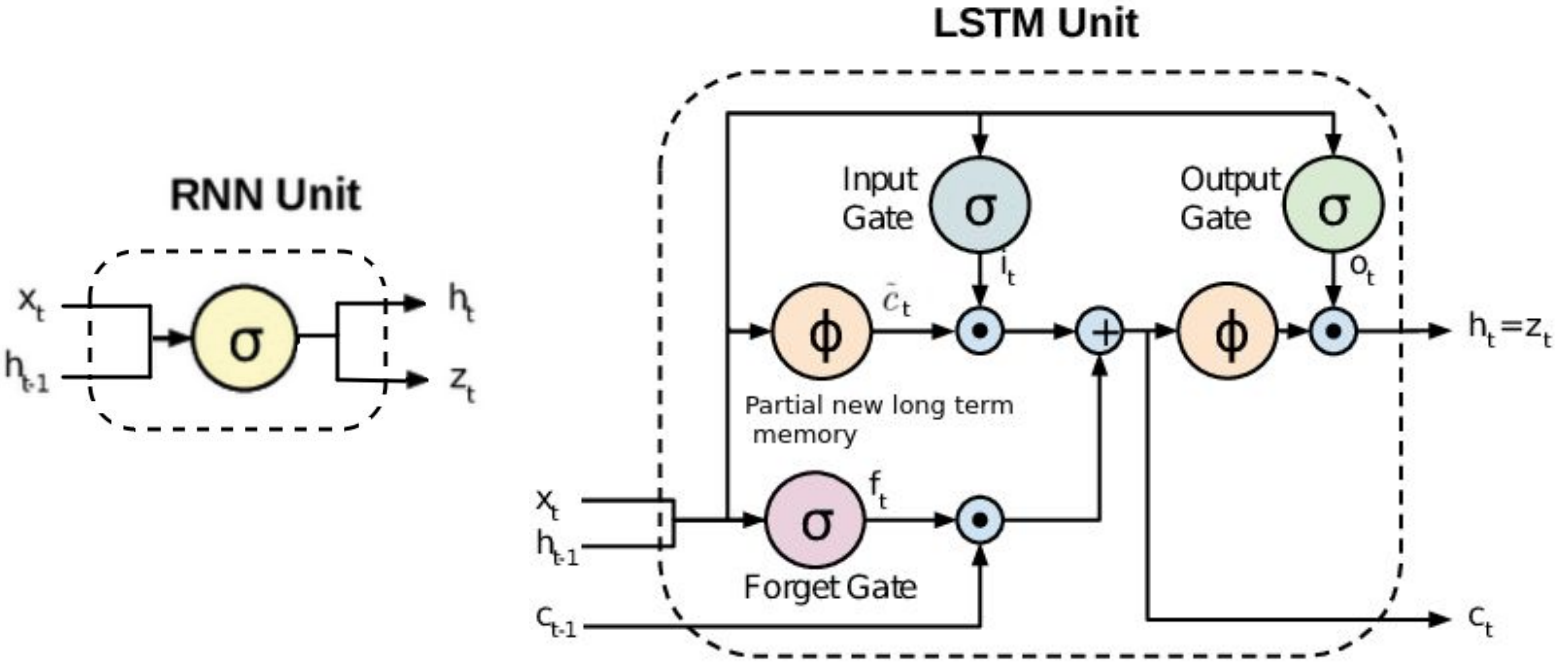

Variantes de la LSTM

Gated Recurrent Unit (GRU): combina las compuertas forget e input en una sola. Disponible en TF.

Peephole LSTM: Se introducen más conexiones hacia las compuertas. Disponible en TF.

Time-Aware LSTM: Permite representar la información de intervalos de tiempo en una secuencia.

Sentiment analysis

"Es una forma de clasificar texto a fin de encontrar la intención o el sentimiento detrás de las palabras (positivo, neutral, negativo"

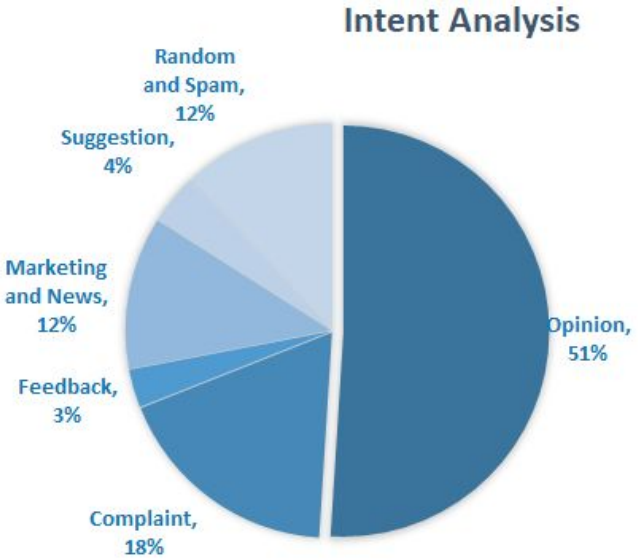

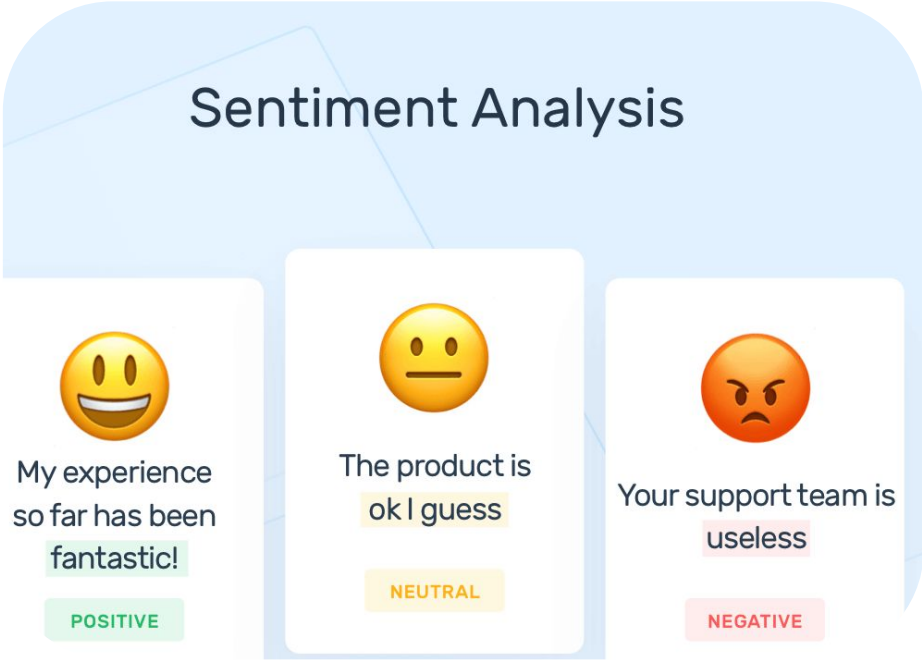

IMDB dataset

Dataset con muchas críticas de películas en formato "positivo" o "negativo" (clasificación binaria de texto)

LINK

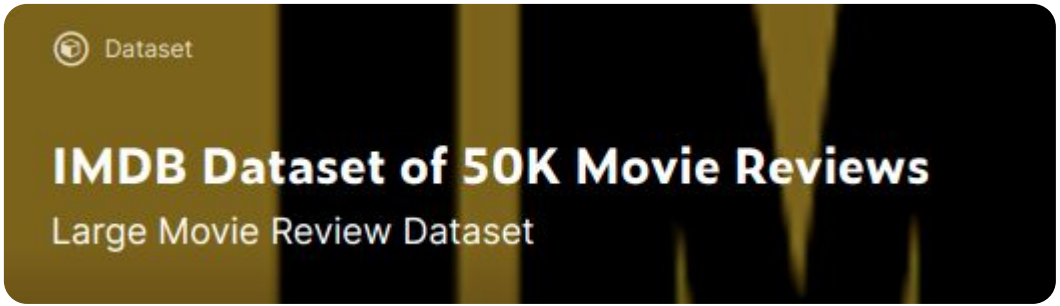

review	sentiment
49582 unique values	2 unique values
One of the other reviewers has mentioned that after watching just 1 Oz episode you'll be hooked. The...	positive
Basically there's a family where a little boy (Jake) thinks there's a zombie in his closet & his par...	negative

Padding

LINK

Hoy trabajaremos con sentiment analysis el cual responde a la estructura many-to-one (text_sequence to class/label)

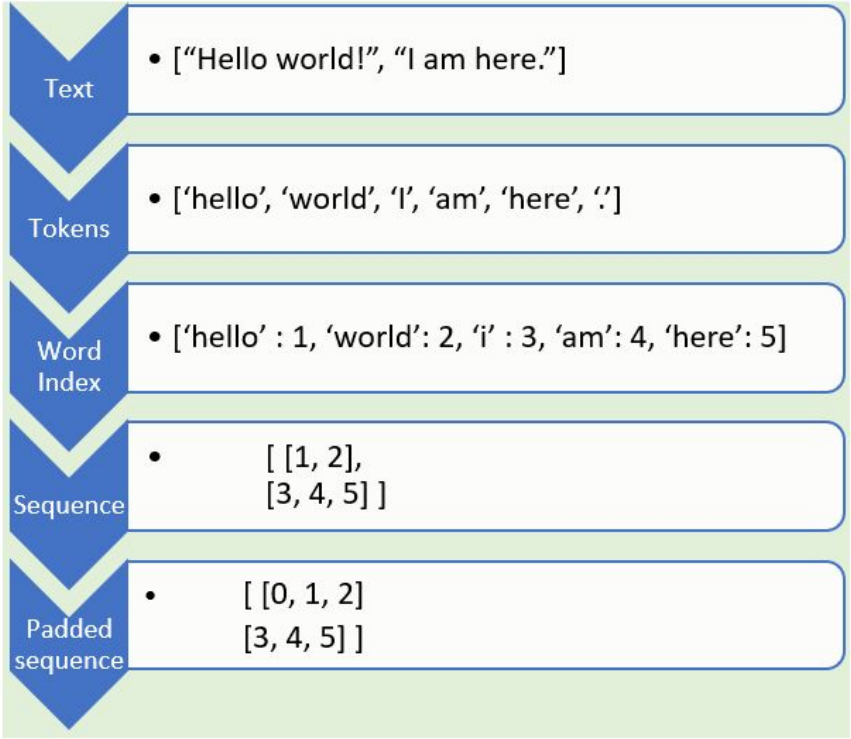

Es necesario garantizar que la longitud de la secuencia de entrada siempre será del mismo largo, para eso se agregan ceros al comienzo o final de las cadenas de texto más cortas (padding)

```
padded_seq =
[[ 2  6  3  7  8]
 [ 0  2  9  3  4] <---------- 0 Padded at the beginning
 [ 0  0  0  5 10]
 [ 0  0  0  5  4]]
```

BOW - Sentiment Analysis

Link al Colab

LINK

TFIDF - Sentiment Analysis

Embeddings + LSTM + Classifier

LINK

Arquitectura de alto nivel de un modelo “sentiment analysis”

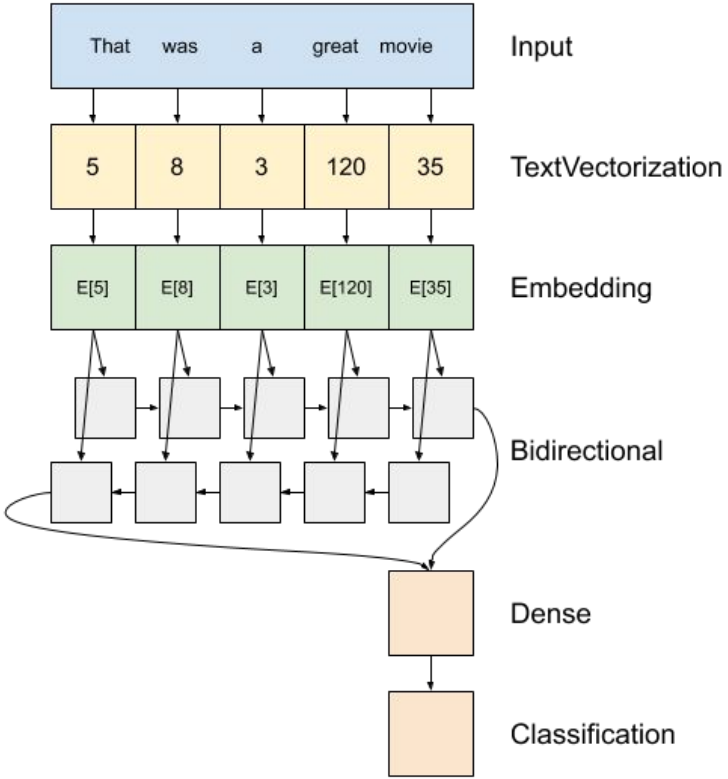

Pre-trained Embedding layer

LINK LINK

"Utilizar embeddings pre-entrenados (GloVe / FastText) en la layer de Embeddings de Keras"

```
Embedding(input_dim=vocab_size,  # definido en el Tokenizador
          output_dim=embed_dim,  # dimensión de los embeddings utilizados
          input_length=in_shape, # máxima sentencia de entrada
          weights=[embedding_matrix],  # matrix de embeddings
          trainable=False))      # marcar como layer no entrenable
```

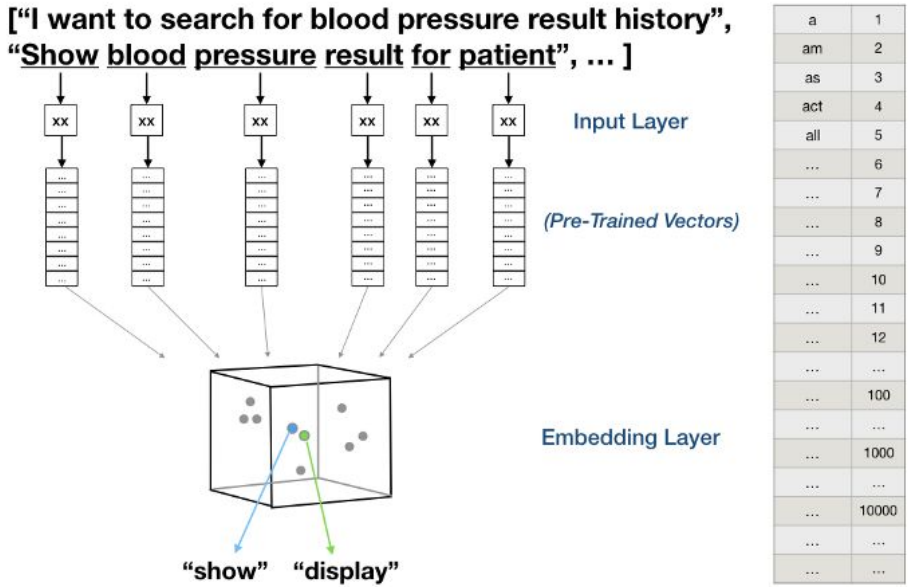

Embeddings + LSTM - Sentiment Analysis

Desafio

Utilizar Embeddings + LSTM para clasificar críticas de compradores de ropa

LINK

Contenido extra
Rápida observación de Speech processing

LINK

Proceso que permite transformar audio a texto (ARS) o texto a audio (TTS)

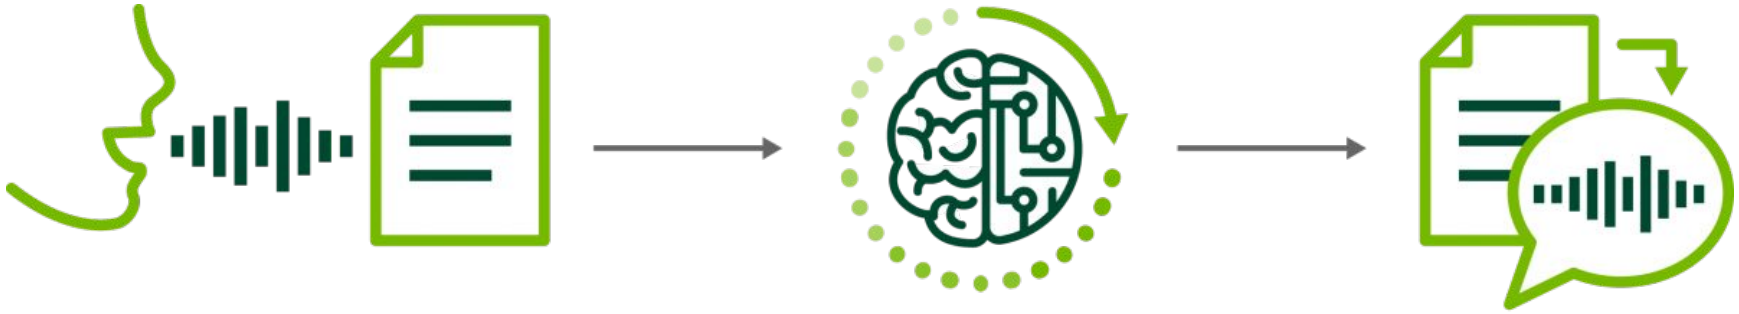

[ASR] [TTS]

Contenido extra
Speech to text (ASR)

LINK

LINK

- Primer proceso es eliminar o ignorar el ruido (filtros)
- Transformar el audio a un espectrograma para obtener features.
- Transformar los features a posibles palabras con un modelo neuronal acústico.
- Utilizar un modelo de NLP para transformar las palabras reconocidas en una sentencia/oración con significado.

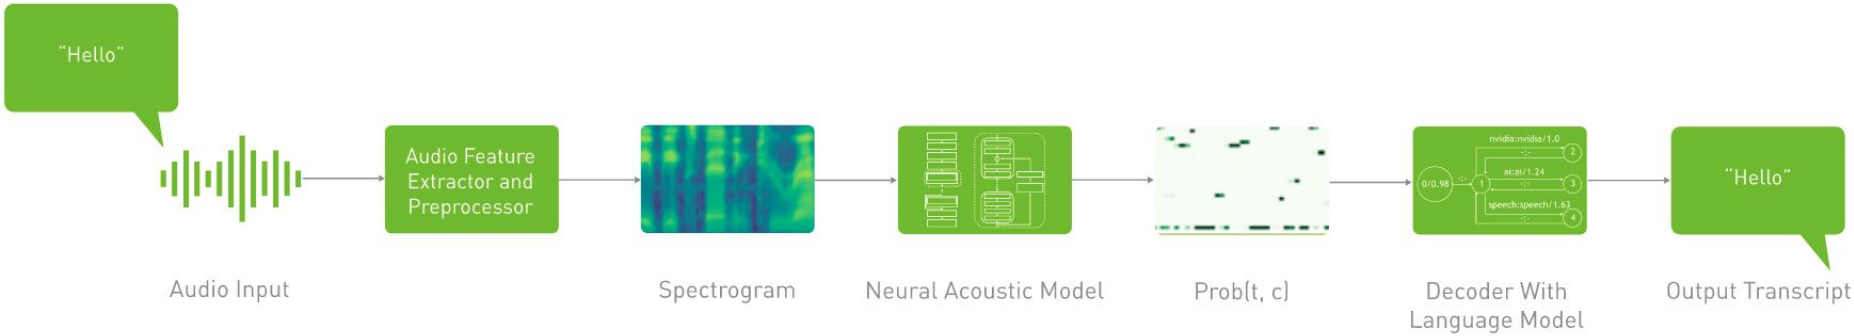

Contenido extra - speech2text

Link al Colab

LINK

¡Muchas gracias!

Gated Recurrent Units (GRU)

LINK

"Evolución de las RNN para superar problemas de "short-memory", versión reducida de una LSTM".

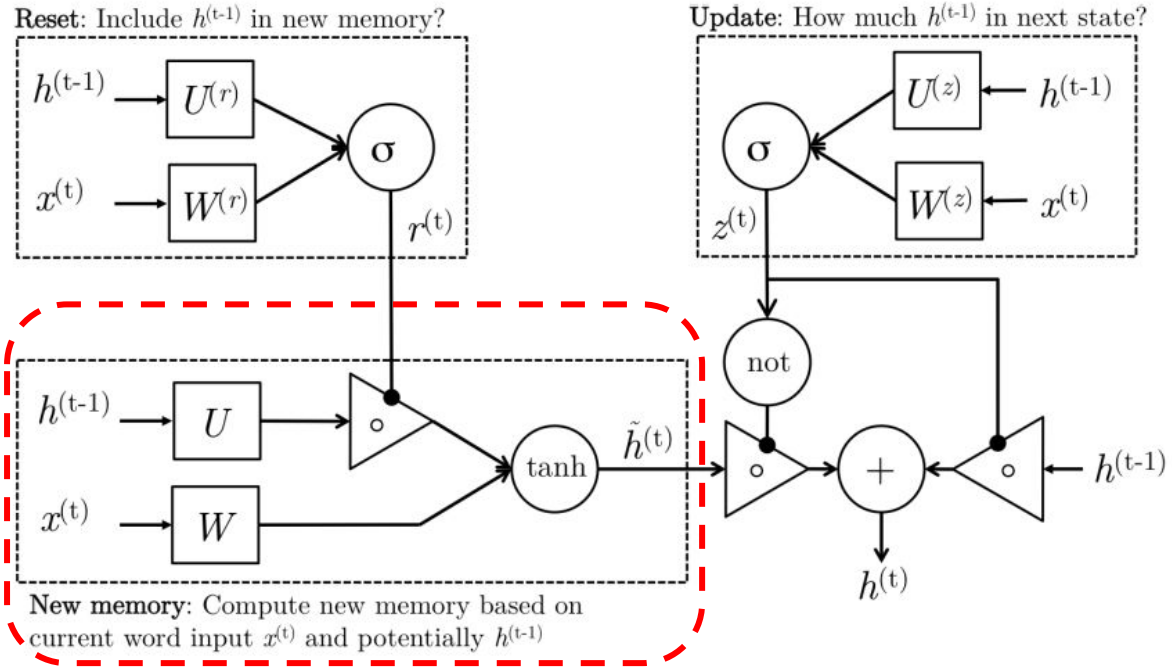

Nuevos pesos a entrenar

$$z_t = \sigma(W^{(z)}x_t + U^{(z)}h_{t-1})$$
$$r_t = \sigma(W^{(r)}x_t + U^{(r)}h_{t-1})$$
$$\tilde{h}_t = \tanh(r_t \circ Uh_{t-1} + Wx_t)$$
$$h_t = (1 - z_t) \circ \tilde{h}_t + z_t \circ h_{t-1}$$

(Update gate)

(Reset gate)

(New memory)

(Hidden state)

Cómo funciona la clásica RNN

GRU - Reset Gate

LINK

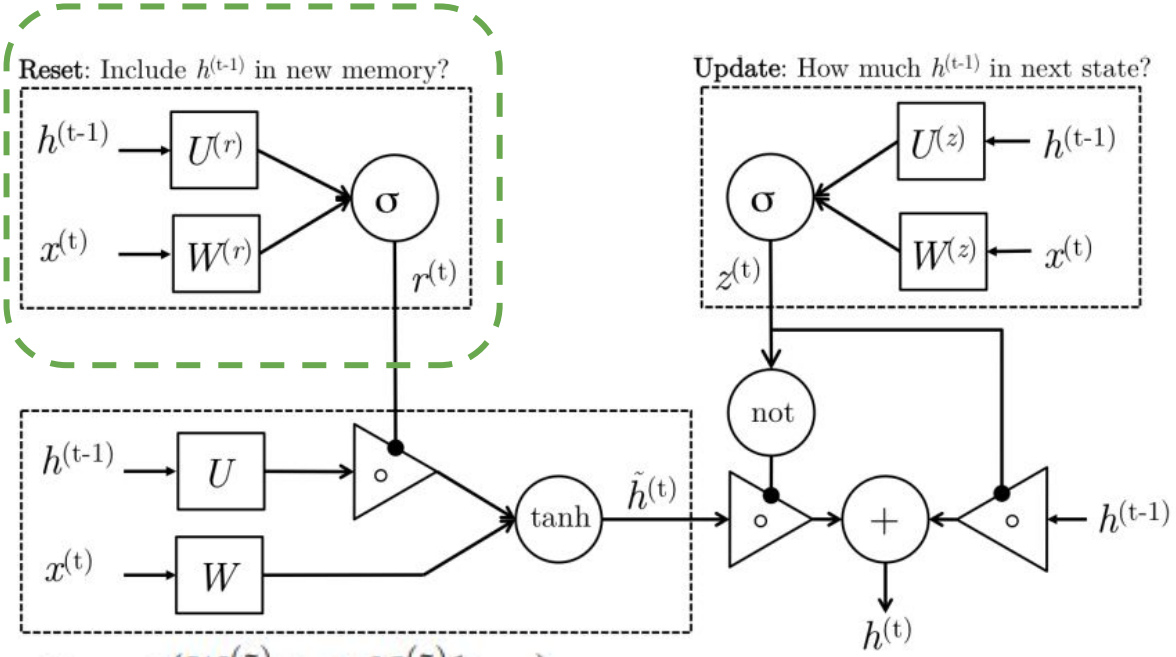

$$z_t = \sigma(W^{(z)}x_t + U^{(z)}h_{t-1})$$
$$r_t = \sigma(W^{(r)}x_t + U^{(r)}h_{t-1})$$
$$\tilde{h}_t = \tanh(r_t \circ Uh_{t-1} + Wx_t)$$
$$h_t = (1 - z_t) \circ \tilde{h}_t + z_t \circ h_{t-1}$$

Determina qué tan importante es el evento pasado (h_{t-1}) en la generación del nuevo estado de memoria (h_t^).

El sistema determina con una sigmoid el grado de (%) que el estado anterior se involucra en el nuevo, pudiendo determinar que este no fluye en absoluto (bypass)

GRU - Update Gate

LINK

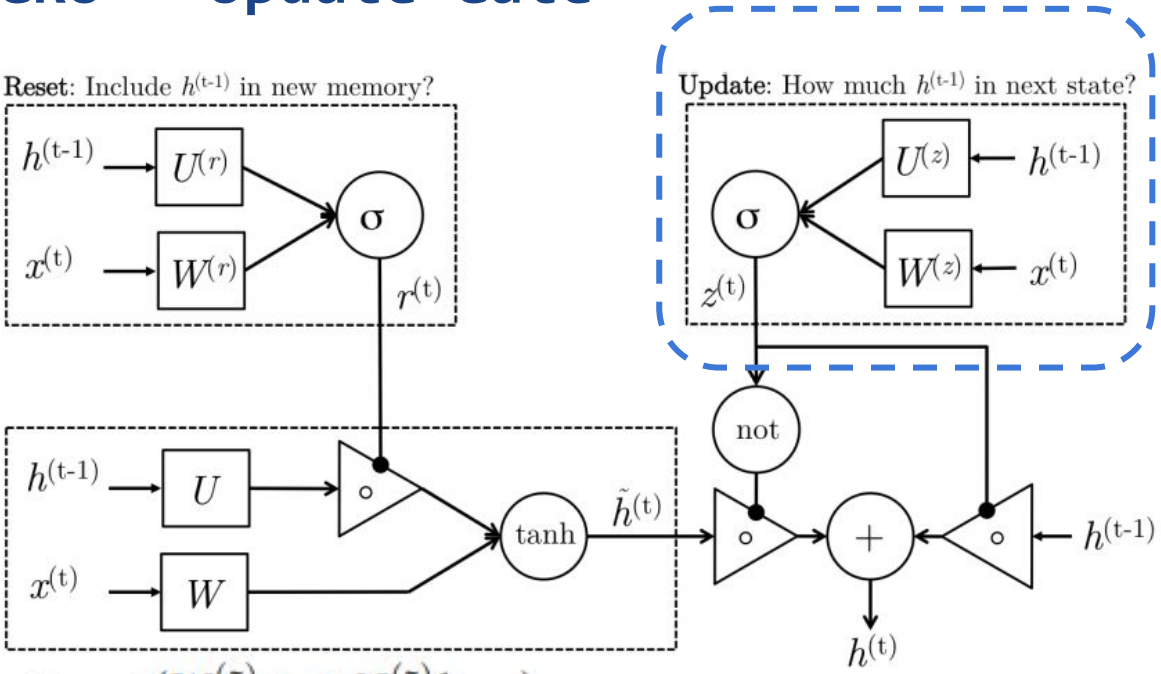

$$z_t = \sigma(W^{(z)}x_t + U^{(z)}h_{t-1})$$
$$r_t = \sigma(W^{(r)}x_t + U^{(r)}h_{t-1})$$
$$\tilde{h}_t = \tanh(r_t \circ Uh_{t-1} + Wx_t)$$
$$h_t = (1 - z_t) \circ \tilde{h}_t + z_t \circ h_{t-1}$$

Determina qué tanto se involucra el estado anterior (h_{t-1}) en la salida del sistema o siguiente estado (h_t). Decide cuánta información nueva agregar o desechar al estado interno de la celda.

El sistema podría determinar que el estado actual no se propague al siguiente estado, y por lo tanto toda la información del estado anterior pasa (bypass) al siguiente.

¿Cómo se refleja el concepto de la memoria?

En este ejemplo se ve como funciona un filtro de media móvil por ventana, en donde el resultado depende de los valores anteriores

D:	10	-2	7	6	2	0
MA:			5	3.66	5	2.66

$$MA_n = \frac{\sum_{i=1}^{n} D_i}{n}$$

Moving average

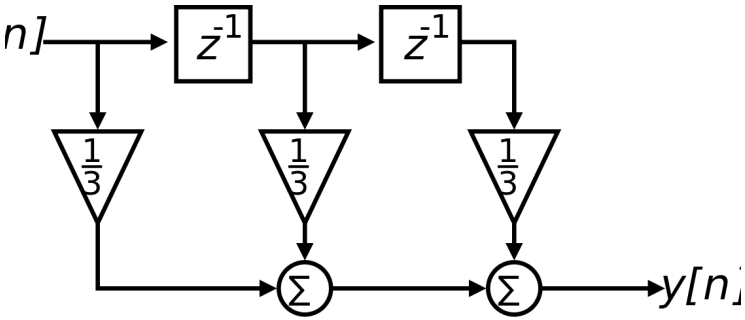

¿Problemas?

Todos los estados tienen el mismo peso o significancia

Tiene problema de memoria corta (los valores salen de la ventana y se olvidan)

¿Cómo se refleja el concepto de gate?

En una red LSTM los valores anteriores están afectados por un coeficiente variable entrenado por la red.

V:	10	-2	7	6	2	0
W:	1	-1	0	2	0	5
M:			4	4.66	4	4

$$M = \frac{\sum_{t=1}^{n} W_t * V_t}{\sum_{t=1}^{n} W_t}$$

M = Average value
V = Actual value
W = Weighting factor
n = Number of periods in the weighting group

Weighted Moving average