

NLP

Long short term memory (LSTM)

Dr. Rodrigo Cardenas Szigety
rodrigo.cardenas.sz@gmail.com

Programa de la materia



Clase 1: Introducción a NLP, Vectorización de documentos.

Clase 2: Preprocesamiento de texto, librerías de NLP y bots de información.

Clase 3: Word Embeddings, CBOW y SkipGRAM, entrenamiento de embeddings.

Clase 4: Redes recurrentes (RNN), problemas de secuencia y estimación de próxima palabra.

Clase 5: Redes LSTM, análisis de sentimientos.

Clase 6: Modelos Seq2Seq, traductores y bots conversacionales.

Clase 7: Celdas con Attention. Transformers, BERT & ELMo, fine tuning.

Clase 8: Cierre del curso, NLP hoy y futuro, deploy.

*Unidades con desafíos a presentar al finalizar el curso.

*Último desafío y cierre del contenido práctico del curso.



"Una celda RNN no puede mantener mucho el contexto o memoria (tienen problemas de short memory) pero se entrenan más rápido y son más baratas de ejecutar (tienen menos parámetros)"

Es muy probable que una celda RNN tenga un buen desempeño en la primera sentencia de ejemplo, pero muy improbable en la segunda por la distancia entre la palabra clave y la palabra objetivo:

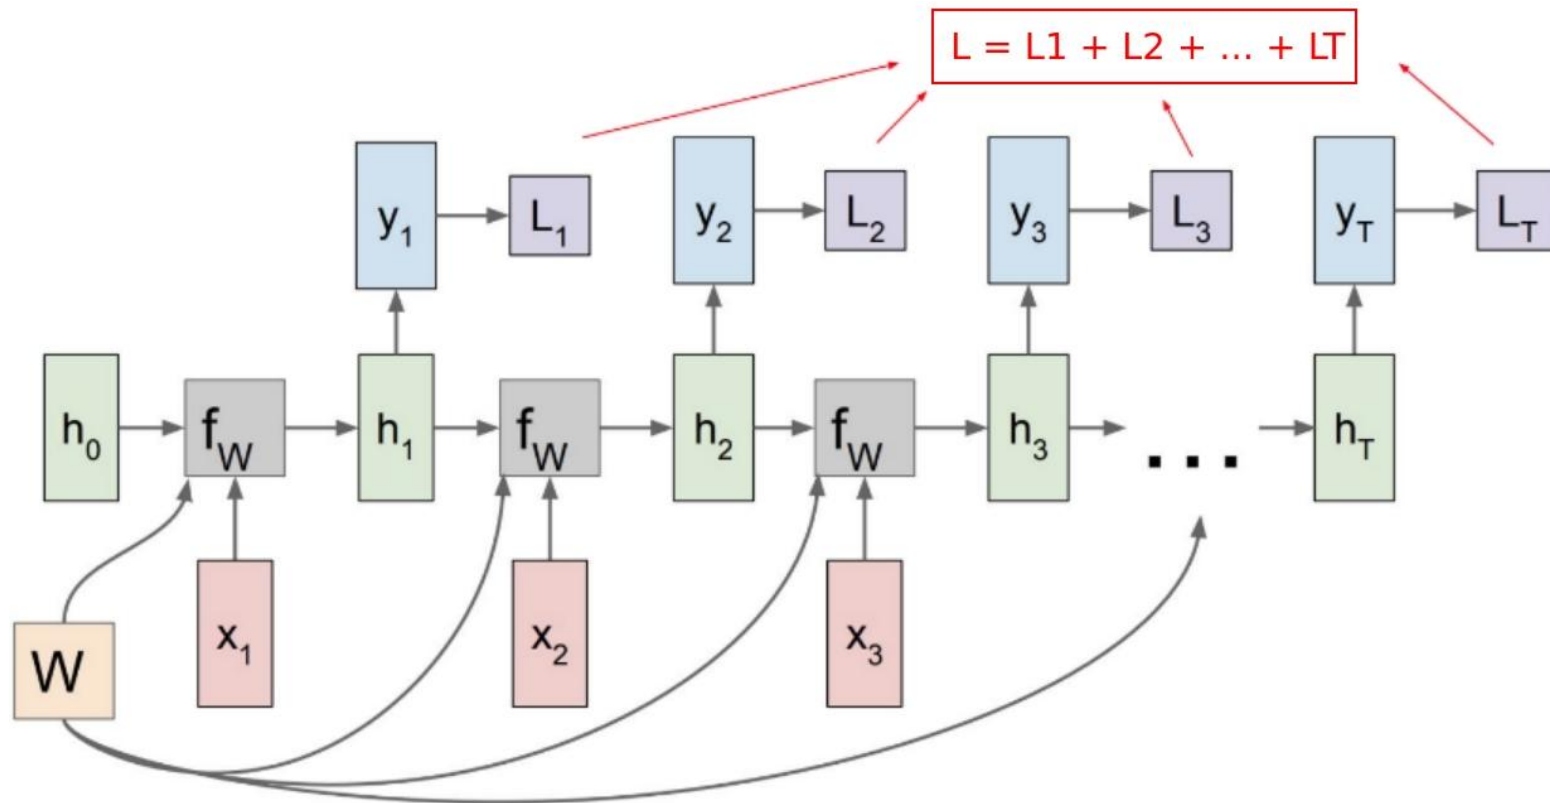
Ejemplo 1:

*"Vivo en **Argentina** desde muy pequeño, donde me enseñaron a hablar castellano"*

Ejemplo 2:

*"Vivo en **Argentina** desde muy pequeño, mis padres viajaron aquí en búsqueda de nuevas oportunidades. En la escuela me enseñaron a hablar muy bien castellano"*

Backpropagation through time (BPTT)



Long short term memory (LSTM)

[LINK](#)



Se introduce este tipo de celda neuronal con mayor persistencia de memoria para lograr capturar relaciones de palabras a largo plazo.



Se crearon en 1997. Se adoptó como la layer principal para problemas de secuencia en 2014 hasta la aparición de los transformers en 2017.



Desplazaron completamente a las capas RNN simples (Elman), ya que el costo adicional de las LSTM es marginal respecto al beneficio que otorgan




Se basan en el principio de ponderar la importancia de una palabra respecto al contexto futuro/pasado (key words).

¿Comprarías este producto?

*"**Incredible!** El producto es lo que venden, hace lo que tiene que hacer y me **ayudó mucho** a resolver los problemas que tenía. Lo **volvería a comprar** sin dudas"*

LSTM approach

[LINK](#)



$$i_t = \sigma(W^{(i)}x_t + U^{(i)}h_{t-1})$$

$$f_t = \sigma(W^{(f)}x_t + U^{(f)}h_{t-1})$$

$$o_t = \sigma(W^{(o)}x_t + U^{(o)}h_{t-1})$$

$$\tilde{c}_t = \tanh(W^{(c)}x_t + U^{(c)}h_{t-1})$$

$$c_t = f_t \circ c_{t-1} + i_t \circ \tilde{c}_t$$

$$h_t = o_t \circ \tanh(c_t)$$

Input: Dado el último estado (h_{t-1}) evalúa cuánto de la nueva entrada (x) se incluirá en la memoria de largo plazo (C_t).

Forget: Dada la entrada (x) cuánto del estado de memoria anterior (C_{t-1}) tiene importancia en el nuevo estado.

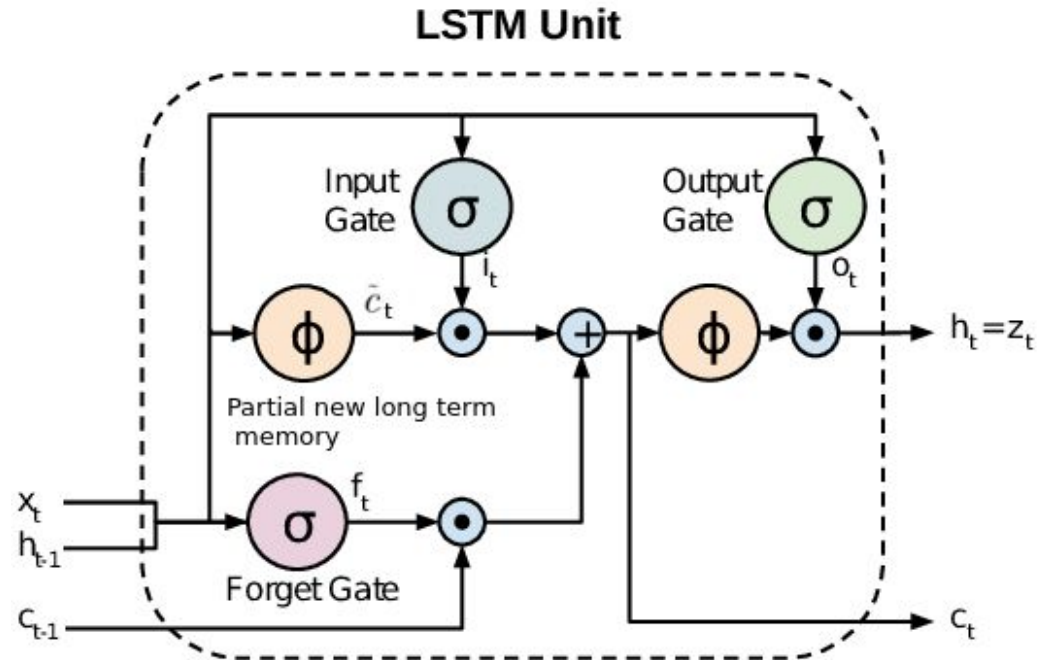

Output: Qué parte del estado de memoria (C_t) pasa al próximo estado de memoria h_t .

(\circ es el producto elemento a elemento)

LSTM vs RNN



La memoria de largo plazo c_t permite propagar gradiente eficientemente a mayor “profundidad temporal”.




Gated Recurrent Units (GRU)

[LINK](#)



"Evolución de las RNN para superar problemas de "short-memory", versión reducida de una LSTM".



$$\begin{aligned} z_t &= \sigma(W^{(z)}x_t + U^{(z)}h_{t-1}) \\ r_t &= \sigma(W^{(r)}x_t + U^{(r)}h_{t-1}) \\ \tilde{h}_t &= \tanh(r_t \circ U h_{t-1} + W x_t) \\ h_t &= (1 - z_t) \circ \tilde{h}_t + z_t \circ h_{t-1} \end{aligned}$$

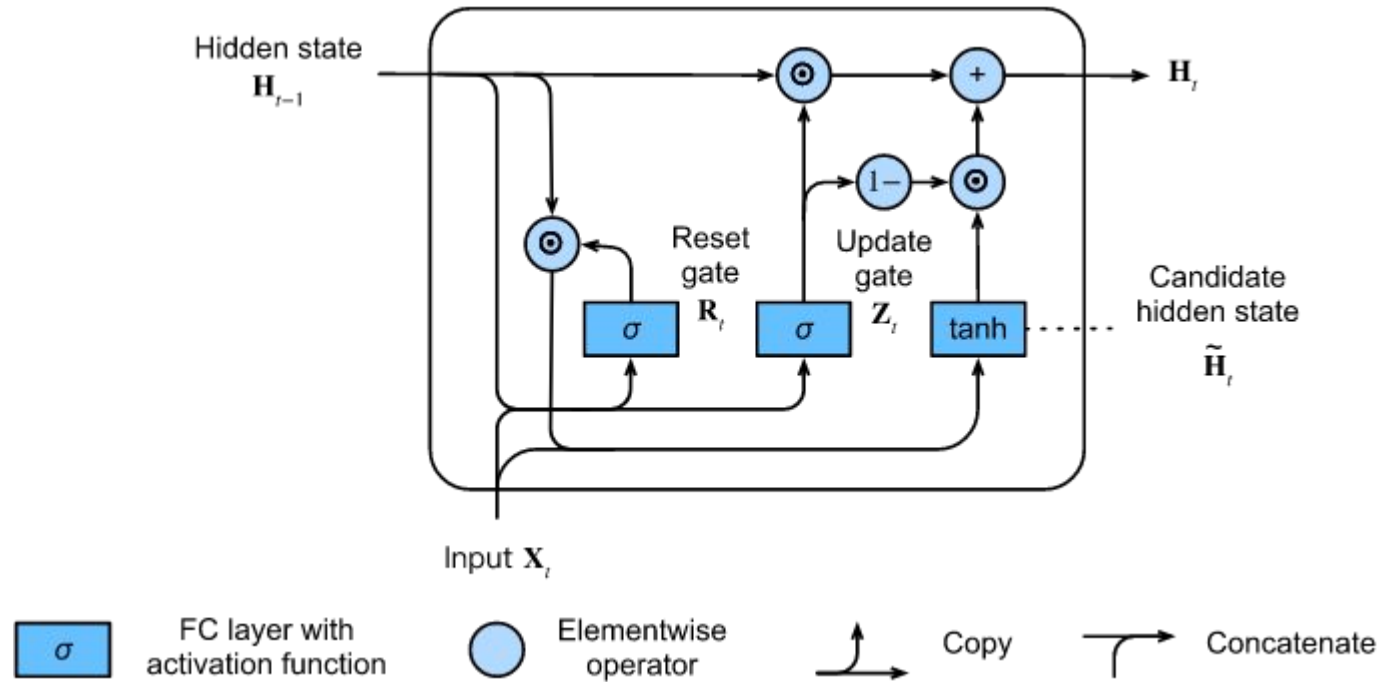
(Update gate)

(Reset gate)

(New memory)

(Hidden state)

Gated Recurrent Units (GRU)





Peephole LSTM: Las compuertas forget, input y output acceden a la memoria de largo plazo. Disponible en los add-ons de TensorFlow.




Time-Aware LSTM: Permite representar la información de intervalos de tiempo transcurrido entre elementos de una secuencia.

Sentiment analysis



"Es una forma de clasificar texto a fin de encontrar la intención o el sentimiento detrás de las palabras (positivo, neutral, negativo)"

Intent Analysis



Sentiment Analysis



My experience
so far has been
fantastic!

POSITIVE



The product is
ok I guess

NEUTRAL



Your support team is
useless

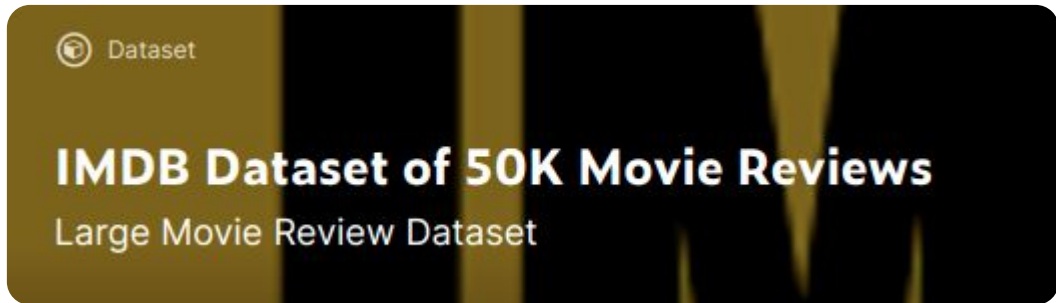
NEGATIVE

IMDB dataset



Dataset con muchas críticas de películas en formato "positivo" o "negativo" (clasificación binaria de texto)

[LINK](#)




review	sentiment
49582 unique values	2 unique values
One of the other reviewers has mentioned that after watching just 1 Oz episode you'll be hooked. The...	positive
Basically there's a family where a little boy (Jake) thinks there's a zombie in his closet & his par...	negative

Padding

[LINK](#)



Hoy trabajaremos con sentiment analysis el cual responde a la estructura many-to-one (text_sequence to class/label)



Es necesario garantizar que la longitud de la secuencia de entrada siempre será del mismo largo, para eso se agregan ceros al comienzo o final de las cadenas de texto más cortas (padding)

```
padded_seq =  
[[ 2  6  3  7  8]  
 [ 0  2  9  3  4] <----- 0 Padded at the beginning  
 [ 0  0  0  5 10]  
 [ 0  0  0  5  4]]
```



Link al Colab



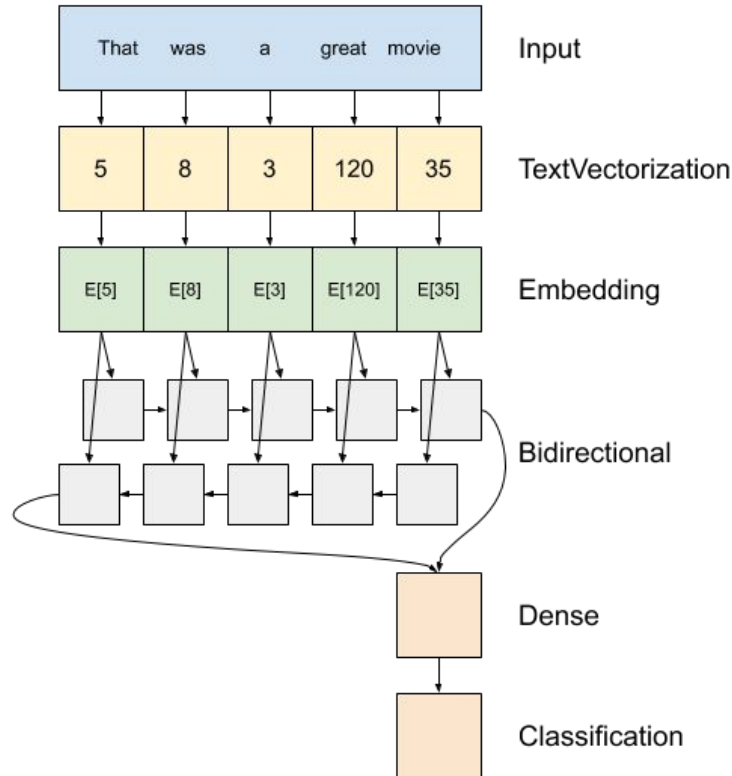
LINK

Embeddings + LSTM + Classifier

[LINK](#)



Arquitectura de alto nivel de un modelo “sentiment analysis”



Pre-trained Embedding layer

[LINK](#)


[LINK](#)



"Utilizar embeddings pre-entrenados (GloVe / FastText) en la layer de Embeddings de Keras"

```
Embedding(input_dim=vocab_size, # definido en el Tokenizador
          output_dim=embed_dim, # dimensión de los embeddings utilizados
          input_length=in_shape, # máxima sentencia de entrada
          weights=[embedding_matrix], # matrix de embeddings
          trainable=False)) # marcar como layer no entrenable
```

**[“I want to search for blood pressure result history”,
“Show blood pressure result for patient”, ...]**



a	1
am	2
as	3
act	4
all	5
...	6
...	7
...	8
...	9
...	10
...	11
...	12
...	...
...	100
...	...
...	1000
...	...
...	10000
...	...
...	...



Link al Colab



LINK



Utilizar Embeddings +
LSTM para clasificar
críticas de
compradores de ropa



LINK



- *Reportar accuracy en conjuntos desbalanceados. Considerar otra métrica (ej: F1-score)*
- *Replicar datos del conjunto de entrenamiento en el conjunto de validación o test por hacer sobremuestreo.*


Contenido extra

Rápida observación de Speech processing

[LINK](#)



Proceso que permite transformar audio a texto (ASR) o texto a audio (TTS)



Contenido extra


Speech to text (ASR)

[LINK](#)

[LINK](#)



- Primer proceso es eliminar o ignorar el ruido (filtros)
- Transformar el audio a un espectrograma para obtener features.
- Transformar los features a posibles palabras con un modelo neuronal acústico.
- Utilizar un modelo de NLP para transformar las palabras reconocidas en una sentencia/oración con significado.



Contenido extra - speech2text con NeMo y Whisper



Link al Colab



[LINK](#)